Adaptive Bagged Boosting – Progress Checkpoint

Autorzy: Mykhailo Shamrai, Grzegorz Prasek · **Prowadzący:** Stanisław Kaźmierczak · **Data:** 10.11.2026

1. Stan realizacji

Etap z harmonogramu	Stan
Implementacja algorytmu bazowego, modyfikacji 1 i 2	zrobione, z testami poprawności (pytest)
Przygotowanie danych	zrobione dla 6 zbiorów pilotażowych; pozostałe 18 do 14.11
Wstępne eksperymenty (pilotaż)	zrobione: 6 zbiorów × 7 metod × 10 przebiegów CV
Strojenie hiperparametrów	do zrobienia (pilotaż na stałych parametrach)

Zaimplementowane metody: pojedynczy GBDT, Bagging drzew, Random Forest oraz cztery warianty baggingu modeli GBDT (Baseline, +1 Adaptive Sampling, +2 Ensemble-Aware Early Stopping, +1+2). Procedura walidacji zgodna z planem: 2×5-fold CV (ziarna 42 i 2026), w każdym foldzie 20% części treningowej jako walidacja wewnętrzna, fold testowy wyłącznie do oceny końcowej.

2. Wyniki pilotażu (wstępne)

Parametry stałe: B=10, M=200, max_depth=3, learning_rate=0.1, α=β=1, k=20, p=2. Bagging i RF: 100 drzew.

Metryka główna, średnia z 10 przebiegów (pełne tabele z odchyleniami: `results/pilot_summary.md`)

Zbiór	GBDT	Bagging	RF	Baseline	+1	+2	+1+2
banknote (F1 ↑)	0.995	0.990	0.992	0.993	**0.996**	0.993	**0.996**
breast_cancer (F1 ↑)	0.955	0.951	0.951	0.956	0.960	0.953	**0.962**
wine (F1 ↑)	0.936	0.961	**0.980**	0.959	0.970	0.959	0.973
auto_mpg (MAE ↓)	2.070	**1.988**	1.992	2.024	2.029	2.047	2.054
concrete (MAE ↓)	**3.403**	3.736	3.731	3.467	3.432	3.481	3.454
yacht (MAE ↓)	**0.351**	0.543	0.540	0.373	0.364	0.378	0.371
Śr. ranga – klasyfikacja	4.67	6.00	4.33	4.17	2.00	5.17	**1.67**
Śr. ranga – regresja	3.00	5.00	4.67	3.67	**2.67**	5.00	4.00

Ensemble-Aware Early Stopping – zbudowane drzewa i czas treningu względem wariantu bez ES

Zbiór	wine	breast_cancer	auto_mpg	banknote	yacht	concrete
Drzewa (+2 vs Baseline)	−36%	−27%	−44%	−6%	−6%	−1%
Czas (+2 vs Baseline)	−21%	−24%	−37%	+2%	+8%	+8%

Obserwacje:

- Adaptive Sampling (+1) poprawia Baseline na 5 z 6 zbiorów; w klasyfikacji wariant +1+2 ma najlepszą średnią rangę. Różnice mieszczą się jednak w odchyleniu standardowym – przy 6 zbiorach to obserwacja, nie wniosek.
- Na regresji pojedynczy GBDT jest konkurencyjny (najlepszy na concrete i yacht), a na auto_mpg wygrywają Bagging i RF.
- Early Stopping zmniejsza liczbę drzew (22–46%) i czas treningu (19–41%) bez utraty jakości tam, gdzie GBDT szybko się nasyca. Gdzie strata walidacyjna spada aż do M=200 (banknote, yacht,

concrete), ES prawie nie przycina modeli, a koszt checkpointów to +2–8% czasu.

3. Doprecyzowania i odstępstwa od planu

1. **Kryterium stopu ES:** log-loss (klasyfikacja) i MAE (regresja) zespołu na walidacji wewnętrznej, zamiast Macro F1. F1 na małej walidacji (np. 29 obserwacji w Wine) zmienia się skokowo i powodował zbyt wczesne zatrzymanie. Poprawa = spadek straty o więcej niż 0,1%.
2. **Normalizacja e_i, d_i w Adaptive Sampling:** podział przez kwantyl 99% i obcięcie do 1, zamiast podziału przez maksimum – pojedyncza obserwacja odstająca nie spłaszcza wag pozostałych. Przy α=β=1 wagi mieszczą się w [1, 3]; efektywna liczność próbki to 92–96% n.
3. **Wspólne dane treningowe:** wszystkie metody trenują na tych samych 80% części treningowej foldu; walidację wewnętrzną wykorzystuje tylko ES (a w pełnych eksperymentach – strojenie).
4. **Przywracanie najlepszego checkpointu ES:** zamiast kopiować model przy każdej poprawie, zapamiętujemy liczbę iteracji i na końcu przycinamy model (test potwierdza identyczne predykcje). Pierwsza wersja z kopiowaniem wydłużała trening nawet o 71%.
5. **Koszt:** raportujemy zarówno drzewa w końcowym zespole, jak i drzewa faktycznie zbudowane (z ES także te za najlepszym checkpointem). W klasyfikacji wieloklasowej sklearn buduje K drzew na iterację.
6. **Dane:** Yacht Hydrodynamics nie jest dostępny przez `ucimlrepo` – pobieramy go bezpośrednio z UCI. Braki liczbowe uzupełniamy medianą z części treningowej foldu (bez wycieku z foldu testowego).

4. Problemy i ryzyka

Ryzyko	Plan działania
ES nie przycina modeli przy M=200 (regresja)	Rozważyć wyższy limit M dla wariantów z ES (np. 500) – do decyzji
Czas pełnych eksperymentów: ok. 57 h na 1 rdzeniu ze strojeniem, ok. 7 h na 8 rdzeniach; Dry Bean i Mushroom to ok. 80% kosztu	Zrównoleglenie po foldach; w razie potrzeby zawężenie siatki dla dużych zbiorów lub `HistGradientBoosting`
Mała liczba zbiorów w pilotażu	Wnioski dopiero po 24 zbiorach i testach Friedmana/Wilcoxona

5. Plan do 24.11

- **11–14.11** – loadery pozostałych 18 zbiorów, strojenie (random search, do 8 konfiguracji), uruchomienie pełnych eksperymentów
- **15–17.11** – tabele wyników, rankingi, test Friedmana i testy Wilcoxona, analiza kosztu
- **18–24.11** – raport końcowy, prezentacja, uporządkowanie kodu

6. Wykorzystanie narzędzi AI

Kod implementacji i eksperymentów powstał z pomocą Claude (Anthropic, Claude Opus 5.5) w Claude Code. Decyzje projektowe i interpretację wyników weryfikowali autorzy. W raporcie końcowym wskażemy zakres wykorzystania AI zgodnie z zasadami przedmiotu.