Politechnika Warszawska

Ensemble Learning
Research Project 2026/2027

Adaptive Bagged Boosting

Adaptive Sampling and
Ensemble-Aware Early Stopping

Final Project Plan

Autorzy:

Mykhailo Shamrai
Grzegorz Prasek

Prowadzący:
Stanisław Kaźmierczak

Warszawa, 18 października 2026

1 Problem badawczy

Metody uczenia zespołowego (*ensemble learning*) pozwalają poprawiać jakość predykcji poprzez łączenie wielu modeli. Dwa popularne podejścia to *bagging* oraz *boosting*.

Bagging polega na trenowaniu wielu modeli na różnych próbkach danych treningowych, a następnie agregowaniu ich predykcji. Jego główną zaletą jest redukcja wariancji, co może poprawiać stabilność modelu i ograniczać przeuczenie.

Boosting wykorzystuje sekwencyjne uczenie modeli, w którym kolejne modele korygują błędy wcześniejszych. Pozwala to często ograniczać obciążenie (*bias*) i modelować bardziej złożone zależności.

Oba podejścia mają jednak swoje ograniczenia. Bagging nie zawsze skutecznie ogranicza obciążenie modelu, natomiast boosting może być wrażliwy na szum w danych oraz nadmiernie dopasowywać się do zbioru treningowego.

W projekcie jako podstawowy algorytm boostingowy planujemy wykorzystać *Gradient Boosting* oparty na drzewach decyzyjnych (GBDT). Wybór ten wynika z możliwości zastosowania algorytmu zarówno w zadaniach klasyfikacji, jak i regresji, a także z możliwości kontrolowania liczby iteracji uczenia.

We wszystkich rozważanych wariantach zastosujemy tę samą architekturę bazową, polegającą na trenowaniu wielu modeli Gradient Boosting na próbkach bootstrapowych i agregowaniu ich predykcji. Pozwoli to porównywać wpływ proponowanych modyfikacji przy zachowaniu wspólnej podstawy algorytmicznej.

Celem projektu jest zbadanie możliwości połączenia zalet baggingu i boostingu poprzez zastosowanie dwóch adaptacyjnych mechanizmów:

1. **Adaptive Sampling** – modyfikacja sposobu losowania próbek treningowych dla kolejnych modeli boostingowych na podstawie informacji o błędach i rozbieżnościach predykcji dotychczasowego zespołu.

2. **Ensemble-Aware Early Stopping** – adaptacyjne określanie liczby iteracji boostingu z uwzględnieniem wpływu kolejnych iteracji na jakość predykcji całego zespołu, a nie wyłącznie pojedynczego modelu.

W ramach projektu planujemy rozważyć cztery warianty algorytmu:

- podstawowy bagging modeli boostingowych,
- bagging z mechanizmem Adaptive Sampling,
- bagging z mechanizmem Ensemble-Aware Early Stopping,
- połączenie obu proponowanych modyfikacji.

Główne pytanie badawcze dotyczy tego, czy zastosowanie wymienionych mechanizmów, osobno lub łącznie, pozwala uzyskać lepszą jakość predykcji, większą stabilność działania lub niższy koszt obliczeniowy w porównaniu z pojedynczym modelem Gradient Boosting oraz klasycznymi metodami zespołowymi.

Zakładamy, że adaptacyjny dobór próbek może zwiększyć różnorodność modeli i poprawić ich współpracę, natomiast uwzględnienie jakości całego zespołu podczas zatrzymywania boostingu może ograniczyć zbędne iteracje uczenia.

Weryfikacja tych założeń zostanie przeprowadzona eksperymentalnie na zbiorach danych klasyfikacyjnych i regresyjnych.

2 Przegląd literatury

Na obecnym etapie projektu zidentyfikowano kilka publikacji dotyczących łączenia baggingu i boostingu oraz mechanizmów zbliżonych do planowanych modyfikacji.

Poniższe prace stanowią punkt wyjścia do dalszego przeglądu literatury. Ich szczegółowa analiza pozwoli lepiej określić istniejące rozwiązania oraz możliwy wkład badawczy projektu.

2.1 Połączenie baggingu i boostingu

1. **MultiBoosting: A Technique for Combining Boosting and Wagging** – Webb (2000) [1].

   Autor przedstawia metodę MultiBoosting, łączącą boosting z waggingiem, podejściem pokrewnym baggingowi. Praca stanowi punkt odniesienia dla naszego podstawowego wariantu łączącego oba mechanizmy.

2.2 Adaptive Sampling – wariant 1

1. **Vote-Boosting Ensembles** – Sabzevari i in. (2018) [2].

   Autorzy proponują metodę, w której wagi przykładów treningowych zależą od stopnia zgodności predykcji modeli w zespole.

   W naszym podejściu planujemy wykorzystać informacje o błędach i rozbieżnościach predykcji do adaptacyjnego losowania próbek bootstrapowych dla kolejnych modeli Gradient Boosting. Dodatkowo chcemy zbadać współdziałanie tego mechanizmu z adaptacyjnym zatrzymywaniem uczenia.

2.3 Ensemble-Aware Early Stopping – wariant 2

1. **agtboost: Adaptive and Automatic Gradient Tree Boosting Computations** – Lunde i Kleppe (2020) [3].

   Autorzy przedstawiają podejście do automatycznego dostosowywania złożoności Gradient Boostingu, w tym liczby drzew. Praca stanowi punkt wyjścia do analizy adaptacyjnego zatrzymywania uczenia modeli boostingowych.

2.4 Połączenie obu modyfikacji

1. **MP-Boost: Minipatch Boosting via Adaptive Feature and Observation Sampling** – Toghani i Allen (2021) [4].

   Autorzy proponują metodę wykorzystującą adaptacyjne próbkowanie obserwacji i cech oraz mechanizm zatrzymywania uczenia na podstawie walidacji out-of-patch.

   W naszym podejściu planujemy wykorzystać bagging wielu modeli Gradient Boosting, zamiast budowania pojedynczego zespołu słabych modeli. Mechanizm zatrzymywania będzie kontrolować liczbę iteracji poszczególnych modeli na podstawie ich wpływu na jakość całego zespołu.

2.5 Planowany kierunek badawczy

Przedstawione publikacje wskazują, że zarówno adaptacyjny dobór próbek, jak i automatyczne zatrzymywanie uczenia były już badane w różnych metodach zespołowych.

W naszym projekcie planujemy zbadać możliwość wykorzystania obu mechanizmów w ramach wspólnej architektury baggingu modeli Gradient Boosting.

Nasze proponowane podejście opisujemy w kolejnym rozdziale.

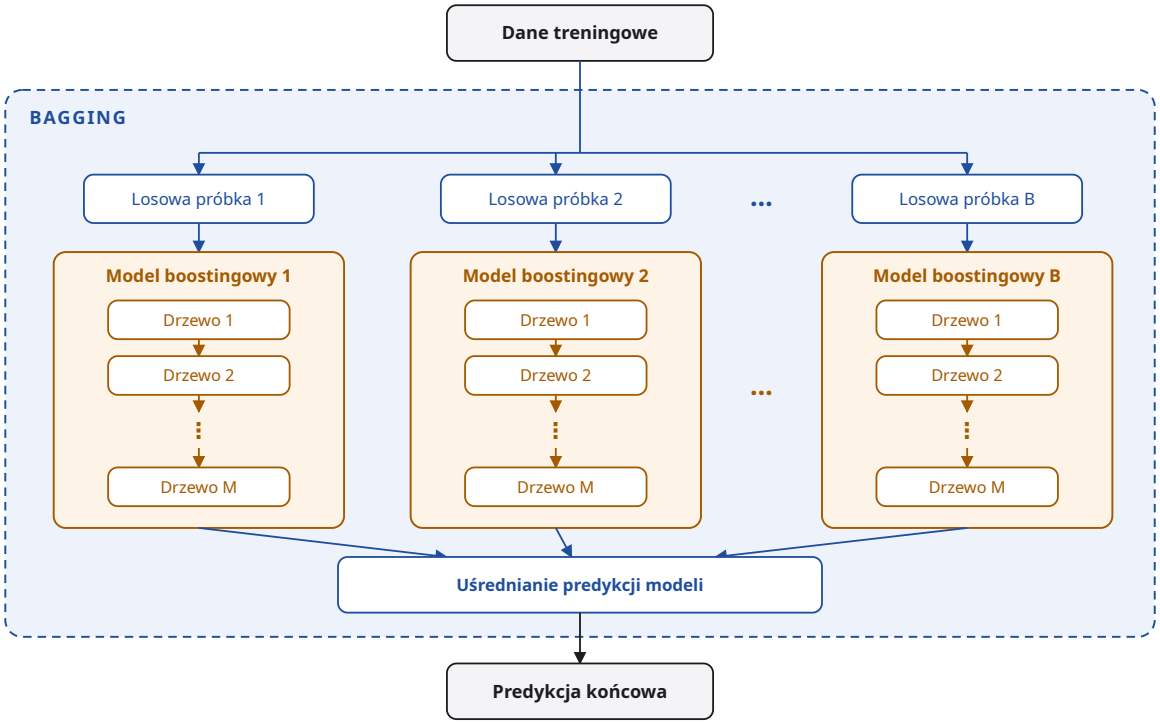
3 Proponowana metoda

Podstawą proponowanego rozwiązania będzie połączenie baggingu z algorytmem Gradient Boosting (GBDT). Planujemy trenować wiele modeli GBDT na różnych próbkach bootstrapowych, a następnie agregować ich predykcje w celu uzyskania końcowego wyniku. Schemat architektury bazowej przedstawiono na rysunku 1.

W ramach projektu proponujemy dwie modyfikacje tego podejścia.

3.1 Adaptive Sampling – modyfikacja 1

Zamiast standardowego losowania próbek bootstrapowych planujemy adaptacyjnie wyznaczać prawdopodobieństwa wyboru poszczególnych obserwacji.



Rysunek 1: Architektura bazowa: bagging modeli Gradient Boosting. Każdy z B modeli zespołu jest trenowany na osobnej próbce bootstrapowej i sam jest zespołem M drzew budowanych sekwencyjnie (boosting). Predykcje modeli są uśredniane (w klasyfikacji – prawdopodobieństwa klas).

Wagi będą zależały od dwóch czynników: błędu predykcji całego zespołu (*Error*) oraz rozbieżności predykcji poszczególnych modeli (*Disagreement*).

Wstępnie zakładamy następującą postać funkcji wag:

$$w_i = 1 + \alpha e_i + \beta d_i$$

gdzie:

- e_i – znormalizowany błąd predykcji dla obserwacji i,
- d_i – znormalizowana rozbieżność predykcji modeli dla obserwacji i,
- α, β – parametry określające znaczenie obu czynników.

Otrzymane wagi zostaną przekształcone w prawdopodobieństwa losowania:

$$P(i) = \frac{w_i}{\sum_{j=1}^{N} w_j}$$

Na tej podstawie będziemy tworzyć próbki treningowe dla kolejnych modeli GBDT.

W przyszłości rozważamy rozszerzenie mechanizmu o analizę postępu uczenia (*Learning Progress*), czyli sprawdzanie, czy kolejne modele rzeczywiście poprawiają wyniki dla poszczególnych obserwacji.

Na obecnym etapie nie uwzględniamy jednak tego rozszerzenia w głównym zakresie badań.

3.2 Ensemble-Aware Early Stopping – modyfikacja 2

Planujemy wprowadzić mechanizm adaptacyjnego zatrzymywania uczenia poszczególnych modeli GBDT na podstawie jakości predykcji całego zespołu.

Podczas trenowania kolejnego modelu co k drzew będziemy wykonywać checkpoint i oceniać jakość całego zespołu z uwzględnieniem aktualnej wersji trenowanego modelu.

Ocena będzie przeprowadzana na wydzielonym zbiorze walidacyjnym przy użyciu wybranej metryki jakości.

Jeżeli kolejne checkpointy nie będą przynosiły poprawy, zakończymy trenowanie danego modelu i przywrócimy jego wersję z najlepszego checkpointu.

Aby uniknąć zatrzymywania uczenia z powodu chwilowych wahań wyników, wprowadzimy parametr p, określający liczbę kolejnych checkpointów bez poprawy, po której trening zostanie zakończony.

Przykładowo dla $k = 20$ oraz $p = 2$ jakość zespołu będzie sprawdzana co 20 drzew. Jeśli przez dwa kolejne checkpointy nie nastąpi poprawa, trening zostanie zatrzymany, a model przywrócony do najlepszego wcześniejszego stanu.

Wartości parametrów k i p zostaną dobrane eksperymentalnie.

3.3 Porównanie wariantów

W ramach eksperymentów porównamy cztery konfiguracje algorytmu:

1. **Baseline** – podstawowy Bagging + Gradient Boosting.
2. **Baseline + 1** – zastosowanie Adaptive Sampling.
3. **Baseline + 2** – zastosowanie Ensemble-Aware Early Stopping.
4. **Baseline + 1 + 2** – jednoczesne zastosowanie obu modyfikacji.

Bazowym punktem odniesienia dla wszystkich czterech wariantów będzie **pojedynczy model Gradient Boosting** (GBDT). Porównanie z nim pozwoli najpierw sprawdzić, czy samo połączenie baggingu z boostingiem (Baseline) poprawia wyniki względem pojedynczego modelu, a następnie – czy proponowane modyfikacje wnoszą dodatkową korzyść.

Zestawienie czterech wariantów pozwoli ocenić wpływ każdej modyfikacji osobno oraz sprawdzić, czy ich połączenie przynosi dodatkowe korzyści w zakresie jakości predykcji, stabilności i kosztu obliczeniowego.

4 Hipotezy badawcze

W ramach projektu planujemy zweryfikować trzy główne hipotezy:

1. **H1 – Adaptive Sampling**

   Adaptacyjny dobór próbek treningowych może poprawić jakość i stabilność predykcji poprzez zwiększenie różnorodności modeli i uwzględnienie trudniejszych obserwacji.

2. **H2 – Ensemble-Aware Early Stopping**

   Zatrzymywanie uczenia na podstawie jakości całego zespołu może ograniczyć koszt obliczeniowy bez istotnego pogorszenia skuteczności predykcji, eliminując zbędne iteracje boostingu.

3. **H3 – Połączenie obu modyfikacji**

   Jednoczesne zastosowanie Adaptive Sampling i Ensemble-Aware Early Stopping może zapewnić lepszy kompromis między jakością predykcji, stabilnością a kosztem obliczeniowym niż każda modyfikacja osobno.

Hipotezy zweryfikujemy poprzez porównanie czterech wariantów algorytmu oraz pojedynczego modelu GBDT na zbiorach klasyfikacyjnych i regresyjnych.

5 Eksperymenty i metryki

5.1 Porównywane metody

Planowane eksperymenty obejmą cztery warianty oparte na tej samej architekturze baggingu modeli GBDT:

1. **Baseline** – zwykłe próbkowanie bootstrapowe, stała liczba drzew w każdym GBDT.
2. **Baseline + 1** – Adaptive Sampling (Error + Disagreement).
3. **Baseline + 2** – Ensemble-Aware Early Stopping.
4. **Baseline + 1 + 2** – obie modyfikacje.

Głównym punktem odniesienia będzie **pojedynczy model Gradient Boosting** (GBDT), strojony w tych samych zakresach hiperparametrów i z tym samym budżetem strojenia co warianty baggingowe. Przy porównaniu kosztu obliczeniowego uwzględnimy, że zespół B modeli zawiera łącznie do $B \cdot M$ drzew. Dodatkowymi punktami odniesienia będą klasyczny bagging drzew decyzyjnych oraz Random Forest. Wszystkie metody będziemy oceniać na identycznych podziałach danych. W czterech głównych wariantach zachowamy ten sam model bazowy, sposób agregacji predykcji i porównywalny budżet strojenia. W regresji predykcje modeli GBDT będą uśredniane; w klasyfikacji uśrednimy prawdopodobieństwa klas.

5.2 Procedura walidacji

Planujemy dwukrotnie powtórzoną walidację 5-fold cross-validation (ziarna losowe 42 i 2026). Dla klasyfikacji zastosujemy podział warstwowy, zachowujący proporcje klas; dla regresji zwykły losowy podział na foldy. Otrzymamy dziesięć ocen każdej metody na każdym zbiorze danych.

W każdym foldzie zewnętrznym dane zostaną podzielone na część treningową oraz niezależną część testową. Z części treningowej wydzielimy 20% obserwacji na walidację wewnętrzną, używaną do strojenia hiperparametrów i kontrolowania Early Stopping. Podział ten będzie taki sam dla wszystkich metod. Zewnętrzny fold testowy nie będzie wykorzystywany do wyboru modelu, parametrów ani momentu zatrzymania.

W modyfikacji 1 informacje o błędach i rozbieżnościach pozyskamy z predykcji OOB: dla każdej obserwacji uwzględnimy wyłącznie te modele zespołu, których próbka bootstrapowa nie zawierała tej obserwacji. Predykcje te obliczymy wyłącznie w obrębie części treningowej i wykorzystamy jako sygnał sterujący treningiem, a nie jako niezależną ocenę generalizacji. W modyfikacji 2 każdy checkpoint będzie oceniany na walidacji wewnętrznej, a do zespołu trafi wersja modelu z najlepszym wynikiem walidacyjnym. Niezależna ocena końcowa nastąpi dopiero na foldzie zewnętrznym.

5.3 Metryki oceny

Dla **klasyfikacji** główną metryką będzie *Macro F1*, a pomocniczą *Accuracy*. Macro F1 nadaje jednakowe znaczenie każdej klasie, co jest istotne przy niezrównoważonych zbiorach.

Dla **regresji** główną metryką będzie *MAE* (średni błąd bezwzględny), a pomocniczą *RMSE* (pierwiastek ze średniego błędu kwadratowego). Niższe wartości obu miar są korzystniejsze.

Dodatkowo zmierzymy czas trenowania, liczbę wytrenowanych drzew i czas predykcji. Czas trenowania będzie obejmował również narzut związany z adaptacyjnym próbkowaniem oraz oceną checkpointów; koszty strojenia podamy oddzielnie.

5.4 Agregacja wyników i analiza statystyczna

Dla każdej metody i każdego zbioru przedstawimy średnią oraz odchylenie standardowe wyników z dziesięciu przebiegów walidacji. Sporządzimy też tabele wyników wszystkich metod oraz ich średnich pozycji rankingowych na zbiorach. Regresję i klasyfikację przeanalizujemy osobno.

Ponieważ MAE i RMSE mają różne skale na różnych zbiorach, nie będziemy bezpośrednio uśredniać surowych błędów między zbiorami. Do porównań przekrojowych wykorzystamy rankingi oraz błędy względne lub znormalizowane (np. MAE podzielone przez odchylenie standardowe zmiennej docelowej w treningu).

Do porównania wielu metod zastosujemy **test Friedmana** osobno dla klasyfikacji i regresji, przy poziomie istotności $\alpha_{\text{stat}} = 0{,}05$. Po wykryciu różnic planujemy porównania parami za pomocą **testu Wilcoxona**. W szczególności sprawdzimy różnice między pojedynczym GBDT a Baseline, między Baseline i każdą modyfikacją oraz między wariantem 1+2 a wariantami 1 i 2. Jednostką porównania statystycznego będzie zbiór danych, a nie pojedynczy fold walidacji.

W raporcie omówimy także przypadki, w których modyfikacje pogarszają wyniki, oraz kompromis między jakością a kosztem obliczeniowym.

6 Datasety i hiperparametry

6.1 Wybrane zbiory danych

Zaplanowaliśmy **12 zbiorów klasyfikacyjnych** i **12 regresyjnych** z UCI Machine Learning Repository: `https://archive.ics.uci.edu/`. Dobraliśmy zbiory o zróżnicowanej liczbie obserwacji, liczbie cech i charakterze problemu. Numery ID poniżej są identyfikatorami UCI; pozwalają jednoznacznie znaleźć i pobrać dane (np. przez `ucimlrepo`).

Tabela 1: Planowane zbiory klasyfikacyjne

ID UCI	Zbiór danych	Rekordy	Klasy
17	Breast Cancer Wisconsin (Diagnostic)	569	2
52	Ionosphere	351	2
109	Wine	178	3
19	Car Evaluation	1728	4
267	Banknote Authentication	1372	2
94	Spambase	4601	2
602	Dry Bean	13611	7
42	Glass Identification	214	6
144	Statlog (German Credit Data)	1000	2
151	Connectionist Bench (Sonar)	208	2
545	Rice (Cammeo and Osmancik)	3810	2
73	Mushroom	8124	2

Tabela 2: Planowane zbiory regresyjne

ID UCI	Zbiór danych	Rekordy	Zmienna docelowa
1	Abalone	4177	Liczba pierścieni (Rings)
9	Auto MPG	398	Zużycie paliwa (mpg)
165	Concrete Compressive Strength	1030	Wytrzymałość betonu
242	Energy Efficiency	768	Heating Load
243	Yacht Hydrodynamics	308	Oporność hydrodynamiczna
291	Airfoil Self-Noise	1503	Poziom hałasu
294	Combined Cycle Power Plant	9568	Moc elektryczna (PE)
477	Real Estate Valuation	414	Cena nieruchomości
162	Forest Fires	517	Spalona powierzchnia (area)
186	Wine Quality (white)	4898	Ocena jakości (quality)
320	Student Performance (Portuguese)	649	Ocena końcowa (G3)
29	Computer Hardware	209	Wydajność CPU (PRP)

Dla zbiorów zawierających kilka plików lub celów przyjmujemy jedną, z góry określoną wersję: *Wine Quality* – `winequality-white.csv`; *Student Performance* – `student-por.csv` i zmienna `G3`; *Energy Efficiency* – `Y1` (Heating Load); *Computer Hardware* – `PRP` jako cel,

bez kolumn `ERP` i identyfikatorów modelu/sprzedawcy. W *Student Performance* usuniemy też `G1` i `G2`, aby nie opierać predykcji na ocenach bezpośrednio poprzedzających wynik końcowy.

6.2 Przygotowanie danych

Dla każdego zbioru najpierw ustalimy cechy wejściowe i zmienną docelową, a następnie sprawdzimy braki danych, typy kolumn i rozkład klas lub wartości celu. Brakujące wartości liczbowe uzupełnimy medianą, a kategoryczne najczęstszą wartością lub osobną kategorią. Zmienne kategoryczne zakodujemy metodą one-hot encoding. Usuniemy identyfikatory, cechy ujawniające wynik oraz kolumny nieprzydatne do predykcji.

6.3 Hiperparametry i strategia strojenia

Wstępnie rozważamy następujące ustawienia; są to **zakresy kandydackie**, a nie wartości ostateczne:

- liczba modeli GBDT w baggingu: $B \in \{5, 10\}$;
- maksymalna liczba drzew w jednym GBDT: $M \in \{100, 200\}$;
- głębokość pojedynczych drzew: `max_depth` $\in \{2, 3\}$;
- tempo uczenia: `learning_rate` $\in \{0{,}05; 0{,}1\}$;
- rozmiar próbki bootstrapowej: 100% wielkości zbioru treningowego, z losowaniem ze zwracaniem;
- modyfikacja 1: współczynniki $\alpha, \beta \in \{0{,}5; 1; 2\}$, dobrane z ograniczonego zestawu par;
- modyfikacja 2: checkpoint co $k \in \{10, 20\}$ drzew oraz $p \in \{2, 3\}$ checkpointów bez poprawy.

Wewnętrzne losowanie obserwacji wewnątrz GBDT wyłączymy (`subsample=1`), aby oddzielić jego efekt od badanego zewnętrznego Adaptive Sampling. Pozostałe parametry, niewymienione wyżej, zostaną ustalone jednakowo dla głównych czterech wariantów lub będą dobierane według tej samej procedury.

Najpierw przeprowadzimy pilotaż na małych zbiorach: Wine, Breast Cancer i Banknote Authentication (klasyfikacja) oraz Yacht, Auto MPG i Concrete (regresja). Zmierzymy czas treningu, zużycie pamięci i liczbę możliwych konfiguracji na dostępnych komputerach. Na tej podstawie ustalimy maksymalny budżet obliczeniowy i ewentualnie zawęzimy wskazane zakresy parametrów. Pilotaż nie będzie wykorzystywał wyników zewnętrznych foldów testowych do podejmowania decyzji.

Parametry będziemy dobierać osobno w ramach części treningowej każdego zewnętrznego foldu, korzystając z niewielkiego przeszukiwania losowego (np. do 8 konfiguracji) ocenianego na walidacji wewnętrznej. Dla wszystkich porównywanych metod zastosujemy z góry ustalony, porównywalny budżet poszukiwania parametrów. Najlepsze ustawienia wybierzemy według Macro F1 (klasyfikacja) lub MAE (regresja), bez dostępu do foldów testowych.

6.4 Powtarzalność eksperymentów

Zapiszemy ziarna losowe, wersje bibliotek, identyfikatory i warianty zbiorów, podziały na foldy, wybrane hiperparametry, czasy wykonywania oraz wyniki poszczególnych uruchomień. Pozwoli to odtworzyć eksperymenty i uzasadnić ewentualne zmiany w planie.

7 Harmonogram realizacji

- **13–20.10.2026** – analiza literatury, doprecyzowanie metody i przygotowanie Final Plan.
- **21.10–03.11.2026** – implementacja algorytmu bazowego, modyfikacji 1 i 2 oraz przygotowanie danych.
- **04–10.11.2026** – wstępne eksperymenty i analiza wyników.
- **11–17.11.2026** – pełne eksperymenty, porównanie wariantów i analiza statystyczna.
- **18–24.11.2026** – przygotowanie raportu, kodu źródłowego i prezentacji końcowej.

8 Wykorzystanie narzędzi AI

Zgodnie z zasadami przedmiotu informujemy o celu i zakresie wykorzystania narzędzi sztucznej inteligencji przy przygotowaniu niniejszego planu.

Narzędzie: Claude (Anthropic), model Claude Opus 5.5, używany w aplikacji Claude Code.

Zakres wykorzystania:

- **Rysunek 1** – diagram architektury bazowej został wygenerowany z pomocą AI na podstawie opisu metody z rozdziału 3. Układ i treść diagramu zweryfikowali autorzy.
- **Korekta redakcyjna** – poprawki literówek oraz drobne poprawki kodu LaTeX

- **Konsultacja merytoryczna** – AI posłużyło do dodatkowej dyskusji merytorycznej na temat zaproponowanych przez autorów metod. Decyzje o uwzględnieniu uwag podjęli autorzy.

Koncepcja metody, hipotezy badawcze oraz decyzje projektowe zostały opracowane przez autorów. Wszystkie fragmenty przygotowane z pomocą AI zostały przez autorów przeczytane i zweryfikowane; autorzy ponoszą pełną odpowiedzialność za treść dokumentu. W raporcie końcowym w ten sam sposób wskażemy fragmenty raportu i kodu źródłowego przygotowane z wykorzystaniem narzędzi AI.

Literatura

[1] Webb, G. I. (2000). *MultiBoosting: A Technique for Combining Boosting and Wagging*. Machine Learning, 40, 159–196. https://doi.org/10.1023/A:1007659514849

[2] Sabzevari, M., Martínez-Muñoz, G., Suárez, A. (2018). *Vote-Boosting Ensembles*. Pattern Recognition, 83, 119–133. https://doi.org/10.1016/j.patcog.2018.05.022

[3] Lunde, B. A. S., Kleppe, T. S. (2020). *agtboost: Adaptive and Automatic Gradient Tree Boosting Computations*. arXiv:2008.12625. https://arxiv.org/abs/2008.12625

[4] Toghani, M. T., Allen, G. I. (2021). *MP-Boost: Minipatch Boosting via Adaptive Feature and Observation Sampling*. IEEE International Conference on Big Data and Smart Computing. https://arxiv.org/abs/2011.07218